

Analyse statistique des données du N_tester

Thomas PIRES

2026-06-15

Ce fichier rassemble toutes les analyses statistiques sur les données du Ntester, issues des essais réalisés chez les producteurs dans le cadre du projet de recherche sur des méthodes alternatives de lutte contre le puceron vert du pêcher. Le fichier s'organise donc en deux parties, l'une sur les données de Arcé Fruits et l'autre sur celles du Fruit d'Henri.

Analyse statistique : Arcé Fruits-Garaco

IMPORTATION DU JEU DE DONNEES

```
# Importation et transformation des données
```

```
dataNtester = read_excel("donnees_ntester.xlsx")
dataNtester$Modalite = as.factor(dataNtester$Modalite)
dataNtester$Bloc = as.factor(dataNtester$Bloc)
dataNtester$Producteur = as.factor(dataNtester$Producteur)
str(dataNtester)
```

```
tibble [16 x 4] (S3: tbl_df/tbl/data.frame)
 $ Producteur: Factor w/ 2 levels "Arce","FruitHenri": 1 1 1 1 1 1 1 1 2 2 ...
 $ Modalite  : Factor w/ 3 levels "D","D+NP","NP": 3 3 3 3 2 2 2 2 1 1 ...
 $ Bloc      : Factor w/ 4 levels "1","2","3","4": 1 2 3 4 1 2 3 4 1 2 ...
 $ TauxC     : num [1:16] 456 444 459 468 459 442 443 471 453 450 ...
```

```
# Filtre des données selon le producteur
```

```
dataNtester_AG = filter(dataNtester,
                        dataNtester$Producteur == "Arce")
```

```
# Vérification de la présence de valeurs manquantes
```

```
colSums(is.na(dataNtester_AG))
```

Producteur	Modalite	Bloc	TauxC
0	0	0	0

EXPLORATION DU JEU DE DONNEES

Le jeu de données contient les variables et covariables suivantes :


- **Modalite**: il s'agit de la stratégie phytosanitaire appliquée sur une partie de la parcelle.
- **Bloc**: les parcelles d'expérimentations sont structurées en quatre blocs expérimentaux, dans le sens du rang.
- **TauxC**: il s'agit du taux de chlorophylle moyen dans les feuilles des arbres. Cette valeur est la moyenne de 30 mesures réalisées avec le N-tester

Nous nous intéressons à la variable à expliquer Y , *TauxC*. L'intérêt ici est de comprendre l'influence de la *Modalite* sur le taux de chlorophylle dans les feuilles.


Avant toute modélisation, nous allons explorer les données afin d'éviter d'éventuelles erreurs. Nous allons procéder selon les étapes suivantes :

1. Analyser les valeurs aberrantes dans Y et la distribution de ses valeurs
2. Analyse du nombre d'observations pour les Xs
3. Analyser la relation potentielle entre Y et X

1. Valeurs aberrantes et distribution des valeurs de Y



Répartition des quantiles de la variable Y



Conclusion : La variable ne semble pas suivre la distribution d'une loi normale.


2. Pour chaque X qualitative : analyse du nombre de modalités et du nombre d'individus par modalité

D	D+NP	NP
0	4	4

Conclusion : Les données sont équilibrées, il n'y aura donc pas d'influence sur les analyses statistiques.

3. Analyse graphique de la relation potentielle entre Y et X

Taux de chlorophylle dans les feuilles selon la modalité



Conclusion : On observe aucune différence nette sur le taux de chlorophylle entre les modalités.

ANALYSE STATISTIQUE

Après l'exploration du jeu de données, nous pouvons maintenant construire un modèle statistique en lien avec notre variable à expliquer. D'après les analyses précédentes, le modèle de régression linéaire mixte de type anova semble le plus approprié pour ces données. Nous prendrons comme effet aléatoire celui des blocs expérimentaux.

1. Construction du modèle

	numDF	denDF	F-value	p-value
(Intercept)	1	3	6610.049	<.0001
Modalite	1	3	0.446	0.5519

Conclusion : La covariable *Modalite* ne possède aucun effet significatif sur le modèle ($Pr(>F) = 0.5519 > 0.05$), ce qui est cohérent avec les observations précédentes et celles observées sur le terrain.

2. Coefficients du modèle final

Linear mixed-effects model fit by REML

Data: dataNtester_AG

	AIC	BIC	logLik
	55.46575	54.63279	-23.73288

Random effects:

Formula: ~1 | Bloc

(Intercept) Residual

StdDev: 10.25914 6.350853

Fixed effects: TauxC ~ Modalite

	Value	Std.Error	DF	t-value	p-value
(Intercept)	453.75	6.032896	3	75.21264	0.0000
ModaliteNP	3.00	4.490731	3	0.66804	0.5519

Correlation:

(Intr)

ModaliteNP -0.372

Standardized Within-Group Residuals:

	Min	Q1	Med	Q3	Max
	-1.1310904	-0.3955181	-0.1715049	0.6053023	0.9158788

Number of Observations: 8

Number of Groups: 4

3. Pouvoir explicatif du modèle final

\$Models

Model: "lme.formula, TauxC ~ Modalite, dataNtester_AG, ~1 | Bloc"

Null: "lme.formula, TauxC ~ 1, dataNtester_AG, ~1 | Bloc"

\$Pseudo.R.squared.for.model.vs.null

Pseudo.R.squared

McFadden 0.0110004

Cox and Snell (ML) 0.0765622

Nagelkerke (Cragg and Uhler) 0.0766172

\$Likelihood.ratio.test

	Df.diff	LogLik.diff	Chisq	p.value
	-1	-0.31861	0.63722	0.42472

\$Number.of.observations

Model: 8

Null: 8

\$Messages

[1] "Note: For models fit with REML, these statistics are based on refitting with ML"


\$Warnings

[1] "None"



Conclusion : Le modèle n'est pas significatif ($p\text{-value} = 0.42 > 0.05$) et possède un pouvoir explicatif faible, puisqu'il explique environ 7% de la variance observée. Ces résultats sont expliqués par le faible nombre de données, en raison de la nature des données (moyenne de 30 mesures).


VALIDATION DE LA MODELISATION

Les conditions d'applications du modèle linéaire général mixte sont la *normalité des résidus* et *l'homogénéité de la variance*. Nous allons donc vérifier ces hypothèses à l'aide de graphiques.




Normal Q-Q Plot





Conclusion : On observe un problème sur la distribution des valeurs de Y, les hypothèses ne sont donc pas respectées.

Vérification des individus influents



Conclusion : On observe quelques individus influents dans le modèle. L'effet notateur sur le choix des feuilles est important et le faible nombre de données influence ce résultat.

CONCLUSION GENERALE

L'analyse ne montre aucune différence significative concernant l'influence de la modalité sur le taux de chlorophylle dans les feuilles. Cependant, le modèle construit est peu robuste et ne vérifie pas les hypothèses nécessaires. Ces résultats sont aussi fortement influencés par la nature de la variable à expliquer. Il serait nécessaire d'obtenir les données brutes du N-tester, afin d'augmenter le nombre de données par modalité.

Analyse statistique : Le Fruit d'Henri-Najireine

IMPORTATION DU JEU DE DONNEES

```
# Filtre des données selon le producteur

dataNtester_FN = filter(dataNtester,
                        dataNtester$Producteur == "FruitHenri")


# Vérification de la présence de valeurs manquantes


colSums(is.na(dataNtester_FN))
```

Producteur	Modalite	Bloc	TauxC
0	0	0	0

EXPLORATION DU JEU DE DONNEES

1. Valeurs aberrantes et distribution des valeurs de Y





Conclusion : La variable ne semble pas suivre la distribution d'une loi normale.


2. Pour chaque X qualitative : analyse du nombre de modalités et du nombre d'individus par modalité

D	D+NP	NP
4	4	0

Conclusion : Les données sont équilibrées, il n'y aura donc pas d'influence sur les analyses statistiques.

3. Analyse graphique de la relation potentielle entre Y et X

Taux de chlorophylle dans les feuilles selon la modalité



Conclusion : On observe aucune différence significative sur le taux de chlorophylle entre les modalités. Cependant, on observe un taux légèrement plus faible pour la modalité Défoliation seule.

ANALYSE STATISTIQUE

1. Construction du modèle

	numDF	denDF	F-value	p-value
(Intercept)	1	3	8665.989	<.0001
Modalite	1	3	4.457	0.1252

Conclusion : La covariable *Modalite* ne possède pas d'effet fixe significatif sur le modèle ($Pr(>F) = 0.1252 > 0.05$), ce qui est cohérent avec les observations précédentes et celles sur le terrain.

2. Coefficients du modèle final

Linear mixed-effects model fit by REML
Data: dataNtester_FN

```

      AIC      BIC    logLik
58.54813 57.71517 -25.27406

Random effects:
Formula: ~1 | Bloc
      (Intercept) Residual
StdDev:    4.453463 12.22532

Fixed effects: TauxC ~ Modalite
              Value Std.Error DF   t-value p-value
(Intercept)  443.50   6.505607  3  68.17197  0.0000
ModaliteD+NP   18.25   8.644603  3   2.11114  0.1252
Correlation:
      (Intr)
ModaliteD+NP -0.664

Standardized Within-Group Residuals:
      Min      Q1      Med      Q3      Max
-1.1614783 -0.6576158  0.1554765  0.5618407  1.1855274

Number of Observations: 8
Number of Groups: 4

```

3. Pouvoir explicatif du modèle final

```

$Models

Model: "lme.formula, TauxC ~ Modalite, dataNtester_FN, ~1 | Bloc"
Null:  "lme.formula, TauxC ~ 1, dataNtester_FN, ~1 | Bloc"

$Pseudo.R.squared.for.model.vs.null
              Pseudo.R.squared
McFadden              0.0624464
Cox and Snell (ML)      0.4002200
Nagelkerke (Cragg and Uhler) 0.4003310

$Likelihood.ratio.test
      Df.diff LogLik.diff  Chisq  p.value
      -1      -2.0448  4.0895  0.043149

$Number.of.observations

Model: 8
Null: 8

$Messages
[1] "Note: For models fit with REML, these statistics are based on refitting with ML"


$Warnings
[1] "None"

```


Conclusion : Le modèle est significatif ($p\text{-value} = 0.04 < 0.05$) et possède un pouvoir explicatif fort, puisqu'il explique environ 40% de la variance observée.



VALIDATION DE LA MODELISATION

Check Normality




Normal Q-Q Plot





Conclusion : On observe un problème sur la distribution des valeurs de Y et sur l'homogénéité de la variance. Ainsi, les hypothèses ne sont pas respectées.



Conclusion : Comme pour l'analyse précédente, on observe quelques individus influents dans le modèle.

CONCLUSION GENERALE

Comme pour l'analyse précédente, la stratégie phytosanitaire n'influence pas le taux de chlorophylle dans les feuilles. Toutefois, il serait intéressant d'obtenir à nouveau les données brutes du N-tester.