

Analyse statistique des données spatiales 2026

Thomas PIRES

2026-07-02

Ce fichier rassemble l'analyse statistique de l'influence de l'environnement parcellaire sur la pression en pucerons, dans le cadre du projet de recherche sur des méthodes alternatives de lutte contre le puceron vert du pêcher. L'analyse se concentre sur l'exploitation de Loreau Productions, site de Saint-Martin-de-Crau.

Analyse statistique : Loreau Productions

IMPORTATION DU JEU DE DONNEES

```
# Importation et transformation des données
```

```
data_Qgis = st_read("donnees_loreaup.shp")
```

Reading layer 'donnees_loreaup' from data source

'C:\Users\thoma\Documents\INHP\M2_PPEH\Stage_sudexpe\Pucerons pêche\Analyse\Donnees2026\Analyse_parcellaire' using driver 'ESRI Shapefile'

Simple feature collection with 124 features and 6 fields

Geometry type: POLYGON

Dimension: XY

Bounding box: xmin: 541232.5 ymin: 5403809 xmax: 546154.8 ymax: 5407597

Projected CRS: RGF93 v1 / Lambert-93

```
data_Qgis = st_transform(data_Qgis, 2154) # Projection Lambert-93
data_Qgis$Défo = as.factor(data_Qgis$Défo)
data_Qgis$Type = as.factor(data_Qgis$Type)
data_Qgis$Défo_num <- ifelse(data_Qgis$Défo == "oui", 1, 0)
data_Qgis$Culture = as.factor(data_Qgis$Culture)
data_Qgis$Pression = factor(data_Qgis$Pression,
                             levels = c("-", "+", "++", "+++"),
                             ordered = TRUE)
data_Qgis$Variete = as.factor(data_Qgis$Variete)
data_exploit = data_Qgis[data_Qgis$Type == "Exploit",]
data_peches = data_Qgis[data_Qgis$Culture == "Pêches",]
str(data_Qgis)
```

Classes 'sf' and 'data.frame': 124 obs. of 8 variables:


```
$ id      : num  1 2 3 4 5 6 7 8 9 10 ...
$ Culture : Factor w/ 10 levels "Abricots","Cerises",...: 6 6 6 6 6 6 6 6 6 6 ...
$ Défo    : Factor w/ 2 levels "FALSE","TRUE": 2 2 2 2 2 2 2 2 2 2 ...
$ Pression: Ord.factor w/ 4 levels "-"<"+"<"++"<"+++": 2 2 2 2 2 2 2 2 2 3 ...
$ Variete : Factor w/ 70 levels "Aline","Amazonite",...: 6 36 44 12 56 28 49 51 11 20 ...
$ Type    : Factor w/ 2 levels "Exploit","Paysage": 1 1 1 1 1 1 1 1 1 1 ...
```

```

$ geometry:sfc_POLYGON of length 124; first list element: List of 1
..$ : num [1:4, 1:2] 541824 542048 542217 541824 5406084 ...
..- attr(*, "class")= chr [1:3] "XY" "POLYGON" "sfg"
$ Défo_num: num 0 0 0 0 0 0 0 0 0 0 ...
- attr(*, "sf_column")= chr "geometry"
- attr(*, "agr")= Factor w/ 3 levels "constant","aggregate",...: NA NA NA NA NA NA NA
..- attr(*, "names")= chr [1:7] "id" "Culture" "Défo" "Pression" ...

```

Cartographie de l'exploitation



EXPLORATION DU JEU DE DONNEES

Le jeu de données contient les variables et covariables suivantes :


- *id*: l'identité d'une parcelle de l'exploitation.
- *Surf ha*: représente la surface en hectare de chaque parcelle.
- *Culture*: chaque parcelle, ou espace paysager, sont caractérisés par l'espèce végétale cultivée ou naturellement présente.
- *Défo*: elle représente le statut de la défoliation de la parcelle, soit "TRUE" pour les parcelles défoliées, soit "FALSE".

- **Pression**: cette variable est la note attribuée à chaque parcelle, afin de représenter la pression en pucerons sur celle-ci. Les notes sont donc ordonnées de la pression la plus faible (-) à la plus forte (+++).
- **Variete**: il s'agit de la variété de pêches pour chaque parcelle de l'exploitation.
- **Type**: il s'agit du type d'espace paysager, afin de différencier les parcelles de l'exploitation, "Exploit", et l'environnement aux alentours, "Paysage".
- **Geometry**: représente les coordonnées spatiales de chaque élément du parcellaire et du paysage. Ces données sont spécifiques au fichier shapefile de QGIS.


Au sein de ces données, nous nous intéressons à l'analyse de la variable à expliquer Y , la *Pression*. Dans notre cas, la *Pression* est une variable aléatoire discrète qualitative, prenant ses valeurs dans l'ensemble ordonné $\{- < + < ++ < +++\}$. Pour expliquer cette variable, nous avons plusieurs covariables Xs , la *Défo*, le facteur *Culture* et la *Variete*. L'intérêt ici est de comprendre l'influence de l'environnement parcellaire, des espèces cultivées et du statut de la défoliation sur l'intensité des attaques de pucerons. Ainsi, cette analyse sera séparée en deux parties, l'une sur l'influence de la défoliation et des cultures/habitats proches et l'autre partie sur l'influence de la distance à une parcelle défoliée sur la pression en pucerons. Pour des raisons de confidentialité, l'ensemble des variétés de l'exploitation ne peut être présenté dans cette analyse.

Pour la première analyse, nous construirons des variables qualitatives, *Culture proche* et *Habitat proche*, où chaque parcelle sera associée à la culture et à l'habitat les plus proches. Comme ces variables sont nécessaires pour l'analyse, leur construction est réalisée en amont.


Cartographie des habitats proches des parcelles



Cartographie des cultures proches des parcelles




Cartographie de la proximité des parcelles à de la défoliation




Avant toute modélisation, nous allons explorer les données afin d'éviter d'éventuelles erreurs. Nous allons procéder selon les étapes suivantes :

1. Analyser les valeurs aberrantes dans Y et la distribution de ses valeurs
2. Analyser le nombre d'observations pour les Xs
3. Analyser la relation potentielle entre Y et les Xs
4. Vérifier la présence d'éventuelles interactions entre les Xs
5. Vérifier la présence d'une éventuelle colinéarité entre les Xs

1. Valeurs aberrantes et distribution des valeurs de Y



Cartographie de la pression en pucerons



Conclusion : La pression est importante sur l'ensemble du parcellaire, seulement neuf parcelles sont classées avec une pression faible.

PARTIE 1 : ANALYSE DE L'ENVIRONNEMENT PARCELLAIRE

2. Pour chaque X qualitatif : analyse du nombre de facteurs et du nombre d'individus par facteurs

Friches Prairies
56 36


Abricots Cerises Herbe Oliviers Pêches Semis Sol_nu
4 2 1 4 65 12 4

FALSE TRUE
19 73


Conclusion : On observe une forte présence de parcelles défoliées, ainsi qu'un paysage marqué par les friches et les prairies.

3. Analyse graphique de la relation potentielle entre Y et X_s


Proportion de parcelles par pression selon le statut de défoliation



Proportion de parcelles par pression selon l'habitat proche



Proportion de parcelles par pression selon la culture proche




Conclusion : On observe une légère différence de pression selon le statut de la défoliation, avec une pression légèrement plus faible lorsque les parcelles sont défoliées. Cependant, pour le facteur habitat proche, la différence de pression est peu marquée. Pour le facteur culture proche, quelques différences existent selon la culture, avec une pression plus importante à proximité des oliviers et cerisiers. Cependant, ces observations se basent sur un faible nombre de données, elles ne représentent pas une conclusion précise.

4. Analyse des interactions entre les X_s : interactions entre la défoliation et les habitats/cultures proches

Il n'y a pas de sens agronomique à étudier l'interaction entre les facteurs de cette analyse. Par conséquent, aucune interaction ne sera prise en compte dans la suite de l'analyse.

5. Vérification d'une éventuelle colinéarité entre les Xs



Conclusion : Il n'y a pas de colinéarité entre les facteurs.

ANALYSE STATISTIQUE

1. Construction du modèle

Après l'exploration du jeu de données, nous pouvons maintenant construire un modèle statistique en lien avec notre variable à expliquer. Le modèle de régression logistique ordinaire est ici le plus approprié pour étudier la distribution d'une variable aléatoire discrète ordonnée. Le modèle CLM est une extension de la régression logistique binaire aux variables qualitatives à trois modalités ou plus qui sont ordonnées, par exemple modéré, moyen et fort. Cela correspond exactement à notre *Pression*, informant sur l'intensité de l'infestation de pucerons. L'hypothèse sous-jacente à ce type de modèle est le parallélisme des niveaux du modèle, c'est à dire que les relations entre les covariables Xs et la variable Y soient les mêmes pour tous les niveaux de Y . Dans notre cas, il faudra donc vérifier que les effets du statut de la défoliation et des facteurs habitats/cultures proches, soient les mêmes selon la *Pression*.

```
Warning: (1) Hessian is numerically singular: parameters are not uniquely determined
In addition: Absolute convergence criterion was met, but relative criterion was not met
Warning: (1) Hessian is numerically singular: parameters are not uniquely determined
In addition: Absolute convergence criterion was met, but relative criterion was not met
Warning: (1) Hessian is numerically singular: parameters are not uniquely determined
In addition: Absolute convergence criterion was met, but relative criterion was not met
Warning: (1) Hessian is numerically singular: parameters are not uniquely determined
In addition: Absolute convergence criterion was met, but relative criterion was not met
```

Single term deletions

Model:

Pression ~ Défo + habitat_proche + culture_proche + Variete

	Df	AIC	LRT	Pr(>Chi)
<none>		156.00		
Défo	1	154.00	0.000	0.99998
habitat_proche	1	159.54	5.545	0.01853 *
culture_proche	4	148.00	0.000	1.00000
Variete	67	147.64	125.637	1.911e-05 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Conclusion : Le facteur variété possède un effet significatif sur la pression en pucerons, cependant le modèle n'arrive pas à ajuster ses coefficients. La grande variabilité et le faible nombre de répétition des variétés, ne permet pas d'établir un modèle robuste. Ainsi, on retire le facteur variété pour la suite de l'analyse, afin de simplifier le modèle.

Single term deletions

Model:

Pression ~ Défo + habitat_proche + culture_proche

	Df	AIC	LRT	Pr(>Chi)
<none>		147.64		
Défo	1	163.16	17.5218	2.84e-05 ***
habitat_proche	1	146.31	0.6759	0.410997
culture_proche	6	157.80	22.1631	0.001131 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Conclusion : Les facteurs défoliations et culture proche possèdent des effets fixes significatifs et le modèle est ajusté. Nous pouvons donc le conserver pour la suite.

2. Coefficients du modèle final

formula: Pression ~ Défo + habitat_proche + culture_proche

data: data_peches

link	threshold	nobs	logLik	AIC	niter	max.grad	cond.H
logit	flexible	92	-62.82	147.64	7(0)	1.55e-10	4.1e+02

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
DéfoTRUE	-2.9031	0.7447	-3.899	9.68e-05 ***
habitat_prochePrairies	-0.4632	0.5679	-0.816	0.41472
culture_procheCerises	6.7505	2.0751	3.253	0.00114 **
culture_procheHerbe	-0.3956	2.6224	-0.151	0.88009
culture_procheOliviers	3.8901	1.8043	2.156	0.03109 *
culture_prochePêches	2.9736	1.2033	2.471	0.01347 *
culture_procheSemis	2.5243	1.3222	1.909	0.05624 .
culture_procheSol_nu	-0.3945	1.5333	-0.257	0.79693

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Threshold coefficients:

	Estimate	Std. Error	z value
- +	-2.595	1.184	-2.192
+ ++	1.804	1.168	1.545

```
++|+++    5.891    1.577    3.734
```

Conclusion : On observe d'après les résultats, que les parcelles défoliées sont significativement ($Pr(>|z|) = 9.68e-05$) moins touchées (-2.90) que les autres. Ce résultat confirme l'efficacité de la défoliation automnale contre le puceron vert du pêcher.

Pour le faceur culture proche, de nombreux résultats significatifs ressortent. La pression en pucerons est significativement plus élevée à proximité de parcelles de cerisiers, d'oliviers et de pêchers. Ces résultats nécessitent d'être approfondis puisqu'ils dépendent fortement du faible nombre de données concernant ces cultures.

3. Individus influents

Pour vérifier si quelques individus sont influents dans le modèle, nous allons comparer un à un tous les coefficients du modèle avec et sans les individus des données. Ensuite les différences entre les coefficients seront classées afin d'identifier les individus les plus influents. Pour des raisons de présentation, seulement les 10 individus les plus influents seront affichés sur le document (les autres individus sont tout de même pris en compte dans l'analyse).

	observation	influence
52	52	28.4720877
74	74	5.7040197
78	78	3.0253488
89	89	1.9417485
54	54	1.9174974
12	12	1.2811267
92	92	0.7211447
65	65	0.6559061
51	51	0.6024504
32	32	0.5275533

Simple feature collection with 1 feature and 20 fields

Geometry type: POLYGON

Dimension: XY

Bounding box: xmin: 544168.9 ymin: 5404909 xmax: 544434.4 ymax: 5405115

Projected CRS: RGF93 v1 / Lambert-93

	id	Culture	Défo	Pression	Variete	Type	geometry
62	62	Pêches	FALSE	+++	Lena Exploit	POLYGON	((544168.9 5404951,...
		Défo_num	dist_defo	Prairies	Vergers	Friches	Peches
62	0	139.9061	734.482	1073.222	1211.417	0	681.9178 147.8479
		Oliviers	Sol_nu	Herbe	Cerises	habitat_proche	culture_proche
62	54.2874	851.0782	631.4766	595.1177		Prairies	Oliviers

Conclusion : Un individu très influent ressort, il s'agit de l'unique parcelle avec la pression "+++". Ce résultat est cohérent puisque cette parcelle construit à elle seule l'information concernant cette pression.

4. Pouvoir explicatif du modèle

N'ayant pas de R^2 comme dans les modèles linéaires, nous pouvons analyser le pouvoir explicatif du modèle à l'aide de la significativité entre le modèle final et le modèle nul (le modèle qui résume les données en un seul paramètre : la moyenne de Y). Pour cela, nous effectuons un test du rapport de vraisemblance (*Likelihood Ratio Test*), pour identifier si le modèle construit est significativement différent du modèle nul.

```
$Models
```

```
Model: "clm, Pression ~ Défo + habitat_proche + culture_proche, data_peches"
```

```
Null: "clm, Pression ~ 1, data_peches"
```

```

$Pseudo.R.squared.for.model.vs.null
              Pseudo.R.squared
McFadden      0.218990
Cox and Snell (ML) 0.318126
Nagelkerke (Cragg and Uhler) 0.385154

$Likelihood.ratio.test
  Df.diff LogLik.diff  Chisq    p.value
    -8      -17.614 35.228 2.4301e-05

$Number.of.observations

Model: 92
Null: 92

$Messages
[1] "Note: For models fit with REML, these statistics are based on refitting with ML"

$Warnings
[1] "None"

```

Conclusion : Le modèle construit apporte une vraie différence au modèle nul, puisque le test est significatif ($p.value = 2.43e-05$). De plus, le modèle possède un bon pouvoir explicatif, puisqu'il explique environ 39% de la variance observée.

VALIDATION DE LA MODELISATION

L'hypothèse principale du modèle logistique ordinaire est que l'effet des variables X_s doit être constant quel que soit le seuil de la variable ordinaire. Nous pouvons donc effectuer un *nominal_test* pour vérifier cette hypothèse.

Tests of nominal effects

```

formula: Pression ~ Défo + habitat_proche + culture_proche
              Df  logLik    AIC    LRT Pr(>Chi)
<none>          -62.819 147.64
Défo             2 -61.281 148.56 3.0761  0.2148
habitat_proche   2 -61.659 149.32 2.3197  0.3135
culture_proche

```


Conclusion : L'hypothèse est bien respectée par les trois facteurs.

CONCLUSION PARTIE 1

Tout d'abord, cette analyse nous permet de confirmer l'efficacité de la défoliation. Toutefois, la nature des données ne permet pas de mettre en évidence une influence des habitats et des cultures proches, sur la virulence des infestations de pucerons. Enfin, la pression semble être fortement influencée par le facteur variété, ce qui nécessite des analyses complémentaires. Ces analyses complémentaires ne seront pas réalisées par manque de temps.

PARTIE 2 : ANALYSE DE LA DISTANCE A LA DEFOLIATION



L'ensemble des parcelles pour lesquelles la distance à la défoliation est égale à zéro, correspond aux parcelles défoliées. Ainsi, pour éviter un problème d'interprétation du facteur distance_défoliation, qui est colinéaire avec le statut de la défoliation (Figure ci-dessous), nous retirons les données des parcelles défoliées de cette variable.



1. Valeurs aberrantes et distribution des valeurs de Y


Les données de la variable à expliquer sont les mêmes que pour la partie 1.

2. Pour chaque X qualitative : analyse du nombre de facteurs et du nombre d'individus par facteurs



Conclusion : La distribution du facteur distance défoliation ne correspond pas à celle d'une loi normale et semble très découpée.

3. Analyse graphique de la relation potentielle entre Y et X_s



Conclusion : On observe aucune relation nette entre la distance à une parcelle défoliée et la pression en pucerons.

ANALYSE STATISTIQUE

1. Construction du modèle

Single term deletions

Model:

Pression ~ dist_defo

	Df	AIC	LRT	Pr(>Chi)
<none>		37.958		
dist_defo	1	36.789	0.83075	0.3621

Conclusion : Le facteur distance défoliation ne possède aucun effet fixe significatif sur la variable à expliquer. Ce résultat peut être expliqué en raison du grand nombre de parcelles défoliées.

2. Pouvoir explicatif du modèle

\$Models

Model: "clm, Pression ~ dist_defo, data_peches_dist"

Null: "clm, Pression ~ 1, data_peches_dist"

```

$Pseudo.R.squared.for.model.vs.null
              Pseudo.R.squared
McFadden      0.0253364
Cox and Snell (ML) 0.0427813
Nagelkerke (Cragg and Uhler) 0.0520483

$Likelihood.ratio.test
  Df.diff LogLik.diff  Chisq p.value
    -1    -0.41537 0.83075 0.36206

$Number.of.observations

Model: 19
Null: 19

$Messages
[1] "Note: For models fit with REML, these statistics are based on refitting with ML"

$Warnings
[1] "None"

```

VALIDATION DE LA MODELISATION

Tests of nominal effects

```

formula: Pression ~ dist_defo
      Df logLik   AIC    LRT Pr(>Chi)
<none>    -15.979 37.958
dist_defo  1 -15.951 39.902 0.056249  0.8125

```

CONCLUSION PARTIE 2

Cette analyse ne permet pas de mettre en évidence une relation entre la distance à une parcelle défoliée et la pression en pucerons sur les pêchers. Pour cette exploitation, les parcelles de pêchers sont toutes défoliées (sauf jeunes vergers), ce qui laisse peu de variation possible à ce facteur. Ainsi, il serait nécessaire d'obtenir des données avec plus de variation, afin de représenter au mieux la situation.