

# Analyse statistique du suivi avant récolte 2026

Thomas PIRES

2026-06-24

Ce fichier rassemble toutes les analyses statistiques sur les données avant récolte chez Mas Rouge, Arcé Fruits et Le Fruit d'Henri, issues des essais réalisés chez les producteurs dans le cadre du projet de recherche sur des méthodes alternatives de lutte contre le puceron vert du pêcher. Le fichier s'organise donc en trois parties pour chacun de ces producteurs. L'analyse chez Mas Rouge concerne la charge des arbres et le calibre des fruits, alors que chez Arcé Fruits et Le Fruit d'Henri les données concernent simplement le calibre.

---

## Analyse statistique : Mas Rouge-Najiris

### IMPORTATION DU JEU DE DONNEES

```
# Importation et transformation des données
```

```
dataCalibre_MN = read_excel("donnees_calibre_mas_rouge.xlsx")
dataCalibre_MN$Modalite = as.factor(dataCalibre_MN$Modalite)
dataCalibre_MN$Calibre = factor(dataCalibre_MN$Calibre,
                                levels = c("C", "B", "A", "AA"),
                                ordered = TRUE)
str(dataCalibre_MN)
```

```
tibble [300 x 2] (S3: tbl_df/tbl/data.frame)
 $ Modalite: Factor w/ 3 levels "D+LAL","D+LIM",...: 2 2 2 2 2 2 2 2 2 2 ...
 $ Calibre : Ord.factor w/ 4 levels "C"<"B"<"A"<"AA": 3 3 3 3 3 3 3 3 3 3 ...
```

```
dataRecolte_MN = read_excel("donnees_charge_mas_rouge.xlsx")
dataRecolte_MN$Modalite = as.factor(dataRecolte_MN$Modalite)
dataRecolte_MN$ID_arbre = as.factor(dataRecolte_MN$ID_arbre)
dataRecolte_MN$ID_charpentiere = as.factor(dataRecolte_MN$ID_charpentiere)
str(dataRecolte_MN)
```

```
tibble [46 x 4] (S3: tbl_df/tbl/data.frame)
 $ Modalite      : Factor w/ 3 levels "D+LAL","D+LIM",...: 2 2 2 2 2 2 2 2 2 2 ...
 $ ID_arbre      : Factor w/ 4 levels "1","2","3","4": 1 1 1 1 2 2 2 2 3 3 ...
 $ ID_charpentiere: Factor w/ 4 levels "charp1","charp2",...: 1 2 3 4 1 2 3 4 1 2 ...
 $ Nb_fruits     : num [1:46] 194 156 192 158 259 233 191 99 211 120 ...
```

```
# Vérification de la présence de valeurs manquantes
```

```
colSums(is.na(dataCalibre_MN))
```

```
Modalite  Calibre
        0         0
```

```
colSums(is.na(dataRecolte_MN))
```

```
Modalite  ID_arbre ID_charpentiere  Nb_fruits
        0         0             0         0
```

## EXPLORATION DU JEU DE DONNEES

Le jeu de données contient les variables et covariables suivantes :

- *Modalite*: il s'agit de la stratégie phytosanitaire appliquée sur une partie de la parcelle.
- *Calibre*: il s'agit du calibre des fruits observés, ordonné du calibre C à AA.
- *ID arbre*: il s'agit de l'arbre identifié pour le comptage du nombre de fruits présents, au nombre de quatre par modalité.
- *ID charpentiere*: il s'agit de l'identité de la charpentière observée, sur l'arbre choisi, pour l'estimation de la charge.
- *Nb fruits*: il s'agit du nombre de fruits par charpentière.

Il y aura une double analyse statistique au sein de ces données :

1. Nous nous intéressons à la variable à expliquer  $Y$ , *Nb-fruits*. Cette analyse permet de comprendre l'influence de la modalité sur la charge des arbres. Cette variable sera donc expliquée par le facteur *Modalite* et l'effet aléatoire du facteur *ID-arbre*.
2. Nous nous intéressons aussi à la variable *Calibre*, afin d'estimer l'influence de la modalité sur le calibre des fruits. De même, cette variable sera expliquée par le facteur *Modalite* et *ID-arbre*.


Ainsi, l'analyse sera séparée en deux grandes parties afin d'étudier les deux variables  $Y$  séparément.

## PARTIE 1 : ANALYSE DE LA CHARGE


Avant toute modélisation, nous allons explorer les données afin d'éviter d'éventuelles erreurs. Nous allons procéder selon les étapes suivantes :

1. Analyser les valeurs aberrantes dans  $Y$  et la distribution de ses valeurs
2. Analyse du nombre d'observations pour les  $Xs$
3. Analyser la relation potentielle entre  $Y$  et les  $Xs$
4. Vérifier la présence d'éventuelles interactions entre les  $Xs$
5. Vérifier la présence d'une éventuelle colinéarité entre les  $Xs$


1. Valeurs aberrantes et distribution des valeurs de  $Y$



**Distribution du nombre de fruits par charpentière**



## Répartition des quantiles de la variable Y




**Conclusion :** La variable semble suivre la distribution d'une loi normale et quelques valeurs extrêmes ressortent.

**2. Pour chaque X qualitative : analyse du nombre de modalités et du nombre d'individus par modalité**

| D+LAL | D+LIM | D+NP |
|-------|-------|------|
| 15    | 15    | 16   |

**Conclusion :** Les données sont plutôt bien équilibrées, il n'y aura pas d'influence sur l'analyse statistique.

### 3. Analyse graphique de la relation potentielle entre $Y$ et $X$



**Conclusion :** On observe aucune relation nette entre la modalité et le nombre de fruits par charpentière, on suppose donc qu'il n'y a aucune relation entre la modalité et la charge des arbres.

## ANALYSE STATISTIQUE

Après l'exploration du jeu de données, nous pouvons maintenant construire un modèle statistique en lien avec notre variable à expliquer. D'après les analyses précédentes, le modèle de régression linéaire mixte de type anova semble le plus approprié pour ces données. Nous prendrons comme effet aléatoire celui de l'effet ID arbre.

### 1. Construction du modèle

|             | numDF | denDF | F-value  | p-value |
|-------------|-------|-------|----------|---------|
| (Intercept) | 1     | 40    | 451.1691 | <.0001  |
| Modalite    | 2     | 40    | 1.1077   | 0.3402  |

**Conclusion :** La modalité ne possède aucun effet significatif sur le modèle ( $p\text{-value} = 0.34 > 0.05$ ), ce qui est cohérent avec les observations précédentes et celles sur le terrain.

## 2. Coefficients du modèle final

Linear mixed-effects model fit by REML

Data: dataRecolte\_MN

| AIC      | BIC      | logLik    |
|----------|----------|-----------|
| 509.4622 | 518.2682 | -249.7311 |

Random effects:

Formula: ~1 | ID\_arbre

(Intercept) Residual

StdDev: 0.005103139 73.22555

Fixed effects: Nb\_fruits ~ Modalite

|               | Value     | Std.Error | DF | t-value   | p-value |
|---------------|-----------|-----------|----|-----------|---------|
| (Intercept)   | 231.53333 | 18.90676  | 40 | 12.246063 | 0.0000  |
| ModaliteD+LIM | -23.40000 | 26.73819  | 40 | -0.875153 | 0.3867  |
| ModaliteD+NP  | 15.59167  | 26.31709  | 40 | 0.592454  | 0.5569  |

Correlation:

(Intr) MD+LIM

ModaliteD+LIM -0.707

ModaliteD+NP -0.718 0.508

Standardized Within-Group Residuals:

| Min        | Q1         | Med        | Q3        | Max       |
|------------|------------|------------|-----------|-----------|
| -1.5721971 | -0.6518671 | -0.1792976 | 0.4407330 | 3.9722016 |

Number of Observations: 46

Number of Groups: 4

## 3. Pouvoir explicatif du modèle final

\$Models

Model: "lme.formula, Nb\_fruits ~ Modalite, dataRecolte\_MN, ~1 | ID\_arbre"

Null: "lme.formula, Nb\_fruits ~ 1, dataRecolte\_MN, ~1 | ID\_arbre"

\$Pseudo.R.squared.for.model.vs.null

Pseudo.R.squared

McFadden 0.0044038

Cox and Snell (ML) 0.0489964

Nagelkerke (Cragg and Uhler) 0.0489970

\$Likelihood.ratio.test

| Df.diff | LogLik.diff | Chisq  | p.value |
|---------|-------------|--------|---------|
| -2      | -1.1555     | 2.3109 | 0.31491 |

\$Number.of.observations

Model: 46

Null: 46

\$Messages


[1] "Note: For models fit with REML, these statistics are based on refitting with ML"

```
$Warnings  
[1] "None"
```

**Conclusion :** Le modèle n'est pas significatif ( $p\text{-value} = 0.31 > 0.05$ ) et possède un pouvoir explicatif très faible, puisqu'il explique environ 5% de la variance observée. Ce résultat est fortement influencé par le nombre de données et la forte variabilité observée.



## VALIDATION DE LA MODELISATION


Les conditions d'applications du modèle linéaire général mixte sont la *normalité des résidus* et l'*homogénéité de la variance*. Nous allons donc vérifier ces hypothèses à l'aide de graphiques.






Normal Q-Q Plot





**Conclusion** : On observe un problème d'homogénéité de la variance.

## Vérification des individus influents




**Conclusion** : On observe un individu fortement influent dans le modèle. L'effet notateur sur le choix de l'arbre est important.

## CONCLUSION PARTIE 1

Après l'analyse statistique des données, nous pouvons conclure que la modalité n'a aucun effet sur la charge des arbres. Cependant, ce résultat est fortement influencé par la nature des données.

## PARTIE 2 : ANALYSE DU CALIBRE

### 1. Valeurs aberrantes et distribution des valeurs de $Y$




**Conclusion** : On observe une forte présence de fruits en calibre B et C.

### 2. Pour chaque $X$ qualitative : analyse du nombre de modalités et du nombre d'individus par modalité

|       |       |      |
|-------|-------|------|
| D+LAL | D+LIM | D+NP |
| 100   | 100   | 100  |

**Conclusion** : Les données sont équilibrées, il n'y aura donc pas d'influence sur les analyses.

### 3. Analyse graphique de la relation potentielle entre $Y$ et $X$



**Conclusion :** On observe une faible différence entre la modalité D+LIM et les autres modalités, puisque celle-ci possède des fruits légèrement plus gros.

## ANALYSE STATISTIQUE

Après l'exploration du jeu de données, nous pouvons maintenant construire un modèle statistique en lien avec notre variable à expliquer. Le modèle de régression logistique ordinale est ici le plus approprié pour étudier la distribution d'une variable aléatoire discrète ordonnée. Le modèle CLM est une extension de la régression logistique binaire aux variables qualitatives à trois modalités ou plus qui sont ordonnées, par exemple modéré, moyen et fort. Cela correspond exactement à notre *Calibre*, informant sur la taille des fruits (petit, moyen et gros). L'hypothèse sous-jacente à ce type de modèle est le parallélisme des niveaux du modèle, c'est à dire que les relations entre les covariables  $X_s$  et la variable  $Y$  soient les mêmes pour tous les niveaux de  $Y$ . Dans notre cas, il faudra donc vérifier que les effets de la modalité soit les mêmes selon le *Calibre*.

### 1. Construction du modèle

Single term deletions

```

Model:
Calibre ~ Modalite
      Df    AIC    LRT Pr(>Chi)
<none>      593.77
Modalite  2 599.19 9.4246 0.008984 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

**Conclusion :** Le facteur modalité possède un effet fixe sur le modèle ( $Pr(>Chi) = 0.008 < 0.05$ ), ce qui est peu cohérent avec les observations sur le terrain.

## 2. Coefficients du modèle final

```

formula: Calibre ~ Modalite
data:    dataCalibre_MN

link threshold nobis logLik AIC    niter max.grad cond.H
logit flexible  300 -291.88 593.77 7(0)  6.37e-07 8.1e+01

```

```

Coefficients:
      Estimate Std. Error z value Pr(>|z|)
ModaliteD+LIM  0.4084      0.2746   1.487   0.137
ModaliteD+NP   -0.4471      0.2771  -1.614   0.107

```

```

Threshold coefficients:
      Estimate Std. Error z value
C|B   -0.9237      0.2027  -4.557
B|A    1.7472      0.2272   7.690
A|AA    5.7474      1.0151   5.662

```


```

contrast      estimate    SE  df z.ratio p.value
(D+LAL) - (D+LIM)  -0.408 0.275 Inf  -1.487  0.2972
(D+LAL) - (D+NP)   0.447 0.277 Inf   1.614  0.2398
(D+LIM) - (D+NP)   0.855 0.281 Inf   3.042  0.0066

```

P value adjustment: tukey method for comparing a family of 3 estimates

## Proportion de fruits par calibre selon la modalité



### 3. Pouvoir explicatif du modèle

\$Models

Model: "clm, Calibre ~ Modalite, dataCalibre\_MN"

Null: "clm, Calibre ~ 1, dataCalibre\_MN"

\$Pseudo.R.squared.for.model.vs.null

|                              | Pseudo.R.squared |
|------------------------------|------------------|
| McFadden                     | 0.0158880        |
| Cox and Snell (ML)           | 0.0309271        |
| Nagelkerke (Cragg and Uhler) | 0.0358968        |

\$Likelihood.ratio.test

| Df.diff | LogLik.diff | Chisq  | p.value   |
|---------|-------------|--------|-----------|
| -2      | -4.7123     | 9.4246 | 0.0089839 |

\$Number.of.observations

Model: 300

Null: 300

\$Messages

[1] "Note: For models fit with REML, these statistics are based on refitting with ML"

```
$Warnings
[1] "None"
```

**Conclusion :** Le modèle est significatif ( $p.value = 0.008 < 0.05$ ) mais possède un pouvoir explicatif très faible, environ 3% de la variance observée est expliquée.

## VALIDATION DE LA MODELISATION

L'hypothèse principale du modèle logistique ordinaire est que l'effet des variables  $Xs$  doit être constant quel que soit le seuil de la variable ordinaire. Nous pouvons donc effectuer un *nominal\_test* pour vérifier cette hypothèse.

Tests of nominal effects

```
formula: Calibre ~ Modalite
      Df logLik   AIC   LRT Pr(>Chi)
<none>    -291.88 593.77
Modalite  4 -288.81 595.62 6.1476   0.1884
```

**Conclusion :** L'hypothèse est bien respectée.

### Vérification des individus influents

Pour vérifier si quelques individus sont influents dans le modèle, nous allons comparer un à un tous les coefficients du modèle avec et sans les individus des données. Ensuite les différences entre les coefficients seront classées afin d'identifier les individus les plus influents. Pour des raisons de présentation, seulement les 10 individus les plus influents seront affichés sur le document (les autres individus sont tout de même pris en compte dans l'analyse).

```
observation influence
201          201 5.3788430
202          202 0.0715012
203          203 0.0715012
204          204 0.0715012
205          205 0.0715012
206          206 0.0715012
207          207 0.0715012
208          208 0.0715012
209          209 0.0715012
210          210 0.0715012
```

**Conclusion :** On observe un individu fortement influent dans le modèle, puisqu'il s'agit du seul fruit de calibre AA.

## CONCLUSION PARTIE 2

Après l'analyse statistique des données, nous pouvons conclure que la modalité a un effet sur le calibre des arbres, la stratégie D+NP possède de plus petits fruits que celle D+LIM. Cependant, ce résultat est influencé par la nature des données, puisque le modèle possède un pouvoir explicatif très faible. Enfn, après échange



avec le producteur et son retour de la station de conditionnement, aucune différence nette n'a été observée entre les modalités.

---

## Analyse statistique : Arcé Fruits-Garaco

### IMPORTATION DU JEU DE DONNEES

```
# Importation et transformation des données
```

```
dataCalibre_AG = read_excel("donnees_arce_calibre.xlsx")
dataCalibre_AG$Modalite = as.factor(dataCalibre_AG$Modalite)
dataCalibre_AG$Calibre = factor(dataCalibre_AG$Calibre,
                                levels = c("B", "A", "AA"),
                                ordered = TRUE)
str(dataCalibre_AG)
```

```
tibble [204 x 2] (S3: tbl_df/tbl/data.frame)
 $ Modalite: Factor w/ 2 levels "D+NP","NP": 2 2 2 2 2 2 2 2 2 2 ...
 $ Calibre : Ord.factor w/ 3 levels "B"<"A"<"AA": 3 3 3 3 3 3 3 3 3 3 ...
```


```
# Vérification de la présence de valeurs manquantes
```

```
colSums(is.na(dataCalibre_AG))
```

```
Modalite  Calibre
      0         0
```

## EXPLORATION DU JEU DE DONNEES

### 1. Valeurs aberrantes et distribution des valeurs de $Y$




**Conclusion** : Les fruits possèdent un calibre A et B en majorité.

### 2. Pour chaque $X$ qualitative : analyse du nombre de modalités et du nombre d'individus par modalité

|      |     |
|------|-----|
| D+NP | NP  |
| 102  | 102 |

**Conclusion** : Les données sont équilibrées, il n'y aura pas d'influence pour les analyses.

### 3. Analyse graphique de la relation potentielle entre $Y$ et $X$



**Conclusion :** On observe une différence de calibre entre ces deux modalités, avec des fruits plus gros dans la modalité NP seul.

## ANALYSE STATISTIQUE

### 1. Construction du modèle

Type I Analysis of Deviance Table with Wald chi-square tests

```
      Df  Chisq Pr(>Chisq)
Modalite 1 27.177 1.856e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

**Conclusion :** Le facteur modalité possède un effet fixe significatif sur le modèle ( $Pr(>Chisq) = 1.856e-07$ ).

## 2. Coefficients du modèle final

```
formula: Calibre ~ Modalite
data:    dataCalibre_AG
```

```
link threshold nobs logLik AIC      niter max.grad cond.H
logit flexible  204  -174.21 354.43 5(0)   6.01e-07 9.9e+00
```

Coefficients:

|            | Estimate | Std. Error | z value | Pr(> z )     |
|------------|----------|------------|---------|--------------|
| ModaliteNP | 1.5382   | 0.2951     | 5.213   | 1.86e-07 *** |


---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Threshold coefficients:

|      | Estimate | Std. Error | z value |
|------|----------|------------|---------|
| B A  | 0.3710   | 0.2014     | 1.841   |
| A AA | 3.3468   | 0.3300     | 10.142  |

## Proportion de fruits par calibre selon la modalité



## 4. Pouvoir explicatif du modèle

\$Models

```
Model: "clm, Calibre ~ Modalite, dataCalibre_AG"
Null:   "clm, Calibre ~ 1, dataCalibre_AG"
```

```

$Pseudo.R.squared.for.model.vs.null
                Pseudo.R.squared
McFadden              0.0779183
Cox and Snell (ML)    0.1343960
Nagelkerke (Cragg and Uhler) 0.1594020

$Likelihood.ratio.test
  Df.diff LogLik.diff  Chisq    p.value
    -1      -14.721  29.443 5.7591e-08

$Number.of.observations

Model: 204
Null: 204

$Messages
[1] "Note: For models fit with REML, these statistics are based on refitting with ML"

$Warnings
[1] "None"

```

**Conclusion :** Le modèle possède un effet significatif ( $p.value = 5.76e-08 < 0.05$ ) et un pouvoir explicatif correct, puisqu'il explique environ 16% de la variance.

## VALIDATION DE LA MODELISATION

Tests of nominal effects

```

formula: Calibre ~ Modalite
      Df logLik   AIC   LRT Pr(>Chi)
<none>    -174.21 354.43
Modalite  1 -173.70 355.40 1.0264    0.311

```

**Conclusion :** L'hypothèse est bien respectée.

## Vérification des individus influents

```

      observation  influence
103           103 0.12971432
104           104 0.12971432
105           105 0.12971432
106           106 0.12971432
107           107 0.12971432
 1              1 0.04551294
 2              2 0.04551294
 3              3 0.04551294
 4              4 0.04551294
 5              5 0.04551294

```

**Conclusion :** Les individus influents sont les fruits en calibre AA sur la modalité D+NP. Le modèle est donc un peu influencé par les calibres extrêmes.

## CONCLUSION GENERALE

Après l'analyse statistique des données, nous pouvons conclure que la modalité a un effet sur le calibre des arbres, la stratégie NP seul possède de plus gros fruits que celle D+NP.

---

## Analyse statistique : Le Fruit d'Henri-Najireine

### IMPORTATION DU JEU DE DONNEES

```
# Importation et transformation des données
```

```
dataCalibre_FN = read_excel("donnees_fruithenri_calibre.xlsx")
dataCalibre_FN$Modalite = as.factor(dataCalibre_FN$Modalite)
dataCalibre_FN$Calibre = factor(dataCalibre_FN$Calibre,
                                levels = c("B", "A", "AA", "AAA"),
                                ordered = TRUE)

str(dataCalibre_FN)
```

```
tibble [205 x 2] (S3: tbl_df/tbl/data.frame)
 $ Modalite: Factor w/ 2 levels "D","D+NP": 1 1 1 1 1 1 1 1 1 1 ...
 $ Calibre : Ord.factor w/ 4 levels "B"<"A"<"AA"<"AAA": 4 4 4 4 4 3 3 3 3 3 ...
```


```
# Vérification de la présence de valeurs manquantes
```

```
colSums(is.na(dataCalibre_FN))
```

```
Modalite  Calibre
      0         0
```

## EXPLORATION DU JEU DE DONNEES

### 1. Valeurs aberrantes et distribution des valeurs de $Y$




**Conclusion** : On observe une forte dominance de fruits de calibre A et AA.

### 2. Pour chaque $X$ qualitative : analyse du nombre de modalités et du nombre d'individus par modalité

D D+NP  
102 103

**Conclusion** : Les données sont plutôt bien équilibrées, il n'y aura pas d'influence sur l'analyse.

### 3. Analyse graphique de la relation potentielle entre $Y$ et $X$



**Conclusion :** On observe une légère différence de calibre entre les deux modalités (de plus gros fruits sur D seule), on peut donc supposer que la modalité possède un effet fixe sur la variable calibre.

## ANALYSE STATISTIQUE

### 1. Construction du modèle

Single term deletions

Model:

Calibre ~ Modalite

|  | Df | AIC | LRT | Pr(>Chi) |
|--|----|-----|-----|----------|
|--|----|-----|-----|----------|

|        |  |        |  |  |
|--------|--|--------|--|--|
| <none> |  | 364.36 |  |  |
|--------|--|--------|--|--|

|          |   |        |        |               |
|----------|---|--------|--------|---------------|
| Modalite | 1 | 373.65 | 11.296 | 0.0007768 *** |
|----------|---|--------|--------|---------------|

---

Signif. codes:  0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

**Conclusion :** Le facteur modalité possède bien un effet fixe significatif sur le modèle ( $Pr(>Chi) = 0.0007 < 0.05$ ).



## 2. Coefficients du modèle final

```
formula: Calibre ~ Modalite
data:    dataCalibre_FN
```

```
link threshold nobs logLik AIC      niter max.grad cond.H
logit flexible  205  -178.18 364.36 7(0)   6.16e-11 1.6e+01
```

Coefficients:

|              | Estimate | Std. Error | z value | Pr(> z )    |
|--------------|----------|------------|---------|-------------|
| ModaliteD+NP | -0.9458  | 0.2859     | -3.308  | 0.00094 *** |


---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Threshold coefficients:

|        | Estimate | Std. Error | z value |
|--------|----------|------------|---------|
| B A    | -4.07564 | 0.45607    | -8.936  |
| A AA   | -0.06866 | 0.19600    | -0.350  |
| AA AAA | 3.12541  | 0.42680    | 7.323   |

## Proportion de fruits par calibre selon la modalité



## 4. Pouvoir explicatif du modèle

\$Models

Model: "clm, Calibre ~ Modalite, dataCalibre\_FN"

```

Null: "clm, Calibre ~ 1, dataCalibre_FN"

$Pseudo.R.squared.for.model.vs.null
              Pseudo.R.squared
McFadden      0.0307243
Cox and Snell (ML) 0.0536112
Nagelkerke (Cragg and Uhler) 0.0643120

$Likelihood.ratio.test
  Df.diff LogLik.diff  Chisq  p.value
    -1      -5.6479 11.296 0.0007768

$Number.of.observations

Model: 205
Null: 205

$Messages
[1] "Note: For models fit with REML, these statistics are based on refitting with ML"

$Warnings
[1] "None"

```

**Conclusion :** Le modèle possède un effet significatif ( $p.value = 0.0007 < 0.05$ ), cependant son pouvoir explicatif est très faible, puisqu'il explique environ 6% de la variance observée.

## VALIDATION DE LA MODELISATION

Tests of nominal effects

```

formula: Calibre ~ Modalite
      Df logLik   AIC   LRT Pr(>Chi)
<none>    -178.18 364.36
Modalite  2 -177.62 367.25 1.1101    0.574

```

**Conclusion :** L'hypothèse est bien respectée.

## Vérification des individus influents

```

      observation influence
102          102 0.2310141
1           1 0.1950728
2           2 0.1950728
3           3 0.1950728
4           4 0.1950728
5           5 0.1950728
103         103 0.1786333
201         201 0.1654881
202         202 0.1654881
203         203 0.1654881

```

**Conclusion :** On observe peu d'individus influents sur le modèle.

## CONCLUSION GENERALE

Après l'analyse statistique des données, nous pouvons conclure que la modalité a un effet sur le calibre des arbres, la stratégie D seule possède de plus gros fruits que celle D+NP. Cependant, ce résultat est influencé par le faible nombre de données.

---

## Graphique bilan des analyses

### IMPORTATION DU JEU DE DONNEES

```
# Importation et transformation des données

dataCalibre = read_excel("donnees_recolte_producteur.xlsx")
dataCalibre$Modalite = as.factor(dataCalibre$Modalite)
dataCalibre$Calibre = factor(dataCalibre$Calibre,
                             levels = c("C", "B", "A", "AA", "AAA"),
                             ordered = TRUE)
dataCalibre$Producteur = as.factor(dataCalibre$Producteur)
str(dataCalibre)

tibble [709 x 3] (S3: tbl_df/tbl/data.frame)
 $ Producteur: Factor w/ 3 levels "Arce","FruitHenri",...: 1 1 1 1 1 1 1 1 1 1 ...
 $ Modalite   : Factor w/ 5 levels "D","D+LAL","D+LIM",...: 5 5 5 5 5 5 5 5 5 5 ...
 $ Calibre    : Ord.factor w/ 5 levels "C"<"B"<"A"<"AA"<...: 4 4 4 4 4 4 4 4 4 4 ...

# Vérification de la présence de valeurs manquantes

colSums(is.na(dataCalibre))
```

| Producteur | Modalite | Calibre |
|------------|----------|---------|
| 0          | 0        | 0       |

## Proportion de fruits par calibre selon la modalité

